I. Introdução

O desenvolvimento de software open-source tem se tornado cada vez mais relevante na indústria de tecnologia. Plataformas como o GitHub possibilitam que desenvolvedores de diferentes partes do mundo colaborem em projetos de software, contribuindo com código, correções de erros, sugestões de melhorias e novas funcionalidades. Dessa forma, repositórios populares na plataforma podem fornecer indícios importantes sobre práticas de desenvolvimento, colaboração e manutenção de software em larga escala.

Este trabalho tem como objetivo analisar características de sistemas open-source populares hospedados no GitHub. Para isso, serão coletados dados dos 1.000 repositórios com maior número de estrelas na plataforma, considerando métricas relacionadas à maturidade dos projetos, frequência de contribuições externas, número de releases, frequência de atualização, linguagens de programação utilizadas e gerenciamento de issues.

A partir dessas métricas, busca-se identificar padrões e tendências no desenvolvimento de sistemas populares, bem como analisar se determinadas características — como idade do projeto, atividade de manutenção e linguagem utilizada — estão associadas à popularidade dos repositórios.

Para orientar a análise, foram definidas as seguintes questões de pesquisa, juntamente com hipóteses iniciais sobre seus resultados:

RQ1: Sistemas populares são maduros/antigos?

Sistemas populares tendem a ser mais antigos, visto que o GitHub é uma plataforma de relevância há vários anos.

RQ2: Sistemas populares recebem muita contribuição externa?

Sim, pois o GitHub possui a feature “fork”: um usuário pode clonar um repositório como uma cópia do material original e realizar mudanças no mesmo da forma que desejar. Após, ele pode criar uma PR com sugestões a serem aplicadas no repo fonte, o que permite uma grande colaboração entre a comunidade.

RQ3: Sistemas populares lançam releases com frequência?

Sistemas populares não lançam releases com frequência, pois visto a quantidade de usuários e o impacto que uma nova versão pode causar nos mesmos, a tendência é terem releases mais controladas.

RQ4: Sistemas populares são atualizados com frequência?

Sim. Com diversos contribuidores e a possibilidade de propor novas mudanças facilmente, sistemas populares podem sofrer atualizações de forma rápida, ainda que essas mudanças não sejam liberadas de imediato aos usuários.

RQ5: Sistemas populares são escritos nas linguagens mais populares?

Não, pois sistemas populares tendem a ter maior idade, e com isso, podem apresentar tecnologias mais legado, incluindo a linguagem de programação.

RQ 06. Sistemas populares possuem um alto percentual de issues fechadas?

Sim, pois sistemas extensos abrangem maior vulnerabilidade/necessidades. Como os projetos são open source, tais pontos podem ser identificados por qualquer usuário do GitHub, e assim abertas issues para resolvê-los.

II. Metodologia

Este trabalho teve como objetivo analisar características de repositórios populares no GitHub a partir de dados obtidos diretamente da API oficial da plataforma. A seguir, descreve-se o processo utilizado para coleta, processamento e análise dos dados necessários para responder às questões de pesquisa propostas.

Coleta de Dados

A coleta de dados foi realizada por meio da API GraphQL do GitHub, que permite consultar múltiplas informações sobre repositórios em uma única requisição. Para autenticação nas requisições foi utilizado um Personal Access Token (PAT) do GitHub, armazenado como variável de ambiente e carregado no script Python utilizando a biblioteca python-dotenv.

As requisições foram feitas utilizando a biblioteca requests, responsável por enviar consultas HTTP ao endpoint da API GraphQL (https://api.github.com/graphql). As consultas foram estruturadas em GraphQL para recuperar, em cada requisição, informações relevantes dos repositórios, tais como:

- data de criação do repositório

- data da última atualização
- linguagem primária
- número de pull requests aceitas
- número de releases
- número total de issues e issues fechadas

Seleção dos Repositórios

Para o estudo, foram selecionados os 1.000 repositórios com maior número de estrelas no GitHub, utilizando o campo stargazers como critério de ordenação. Como a API retorna no máximo 100 repositórios por requisição, foi necessário utilizar paginação, utilizando o cursor endCursor retornado pela API para acessar as páginas seguintes de resultados.

Assim, foram realizadas múltiplas requisições até atingir o total de 1.000 repositórios analisados.

Processamento e Armazenamento dos Dados

Os dados retornados pela API foram processados em um script Python que extraiu as métricas necessárias para cada repositório. Em seguida, os dados foram estruturados em formato tabular e exportados para um arquivo CSV, permitindo posterior análise estatística.

Para cada repositório foram coletadas as seguintes informações:

- nome do repositório
- linguagem principal
- data de criação
- data da última atualização
- número de pull requests aceitas
- número de releases

- número total de issues
- número de issues fechadas

A partir dessas informações, foram calculadas métricas derivadas necessárias para responder às questões de pesquisa, tais como:

- idade do repositório (diferença entre a data atual e a data de criação)
- tempo desde a última atualização
- razão entre issues fechadas e total de issues

Análise dos Dados

Após a coleta e organização dos dados, foi realizada uma análise estatística baseada principalmente em valores medianos, conforme solicitado no enunciado do laboratório. A mediana foi utilizada por ser menos sensível a valores extremos e fornecer uma visão mais representativa do comportamento geral dos repositórios analisados.

Para métricas categóricas, como linguagem de programação, foi realizada uma contagem de frequência por categoria, permitindo identificar quais linguagens aparecem com maior frequência entre os repositórios populares.

Essas análises permitiram responder às questões de pesquisa relacionadas à maturidade dos projetos, frequência de contribuições externas, atividade de releases, frequência de atualização e linguagens utilizadas em repositórios populares do GitHub.

Ferramentas Utilizadas

As principais ferramentas utilizadas no desenvolvimento do estudo foram:

- Python para implementação do script de coleta de dados
- Requests para realização das requisições HTTP à API do GitHub
- GitHub GraphQL API para obtenção estruturada dos dados dos repositórios
- CSV para armazenamento dos dados coletados e posterior análise

Essa metodologia permitiu coletar e organizar um conjunto consistente de dados sobre repositórios populares, possibilitando a análise das características investigadas nas questões de pesquisa.

III. Resultados

Nesta seção são apresentados os resultados obtidos a partir da análise dos dados coletados dos 1.000 repositórios mais populares do GitHub, considerando as métricas definidas nas questões de pesquisa.

RQ1: Sistemas populares são maduros/antigos?

Para responder a essa questão foi utilizada a métrica de idade do repositório em dias, calculada a partir da data de criação do projeto. A mediana obtida foi de 3061,5 dias, o que corresponde aproximadamente a 8,4 anos.

Esse valor indica que, em geral, os repositórios populares possuem uma idade relativamente elevada. Portanto, os dados sugerem que projetos populares tendem a ser mais maduros e estabelecidos, possivelmente porque tiveram mais tempo para atrair usuários e contribuições da comunidade.

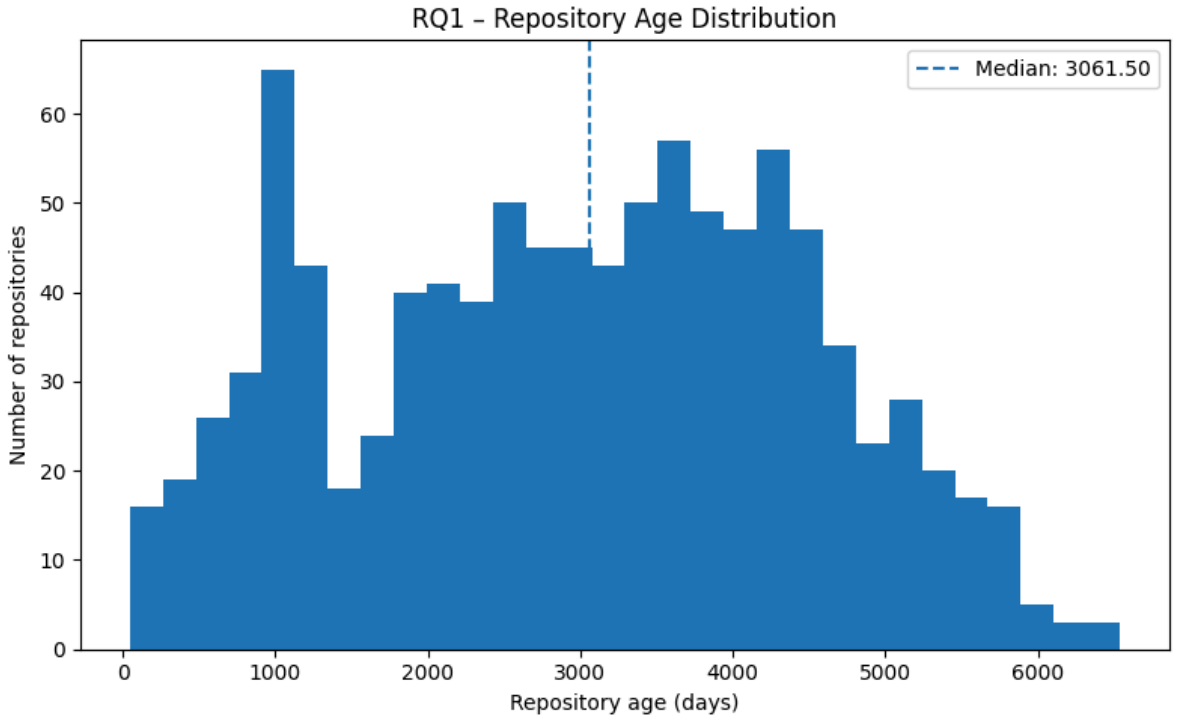

RQ2: Sistemas populares recebem muita contribuição externa?

A métrica utilizada foi o número total de pull requests aceitas (merged pull requests). A mediana encontrada foi de 739 pull requests aceitas.

Esse valor indica que os repositórios populares recebem uma quantidade significativa de contribuições externas. Isso reforça a ideia de que projetos populares costumam possuir comunidades ativas, nas quais diversos desenvolvedores contribuem com melhorias, correções e novas funcionalidades.

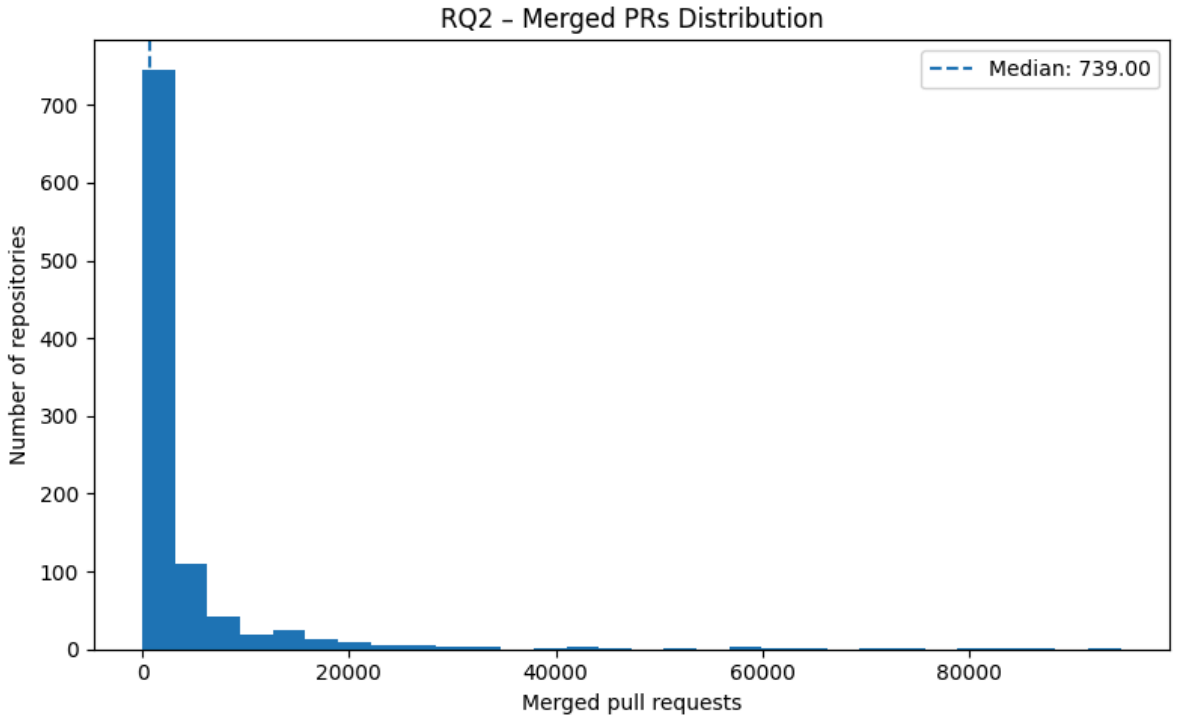

RQ3: Sistemas populares lançam releases com frequência?

Para essa análise foi considerada a quantidade total de releases de cada repositório. A mediana obtida foi de 40,5 releases.

Esse valor indica que muitos projetos populares possuem diversas versões lançadas ao longo do tempo. Isso sugere que, embora os releases possam ser controlados, esses projetos ainda realizam atualizações oficiais com certa

regularidade ao longo de sua evolução.

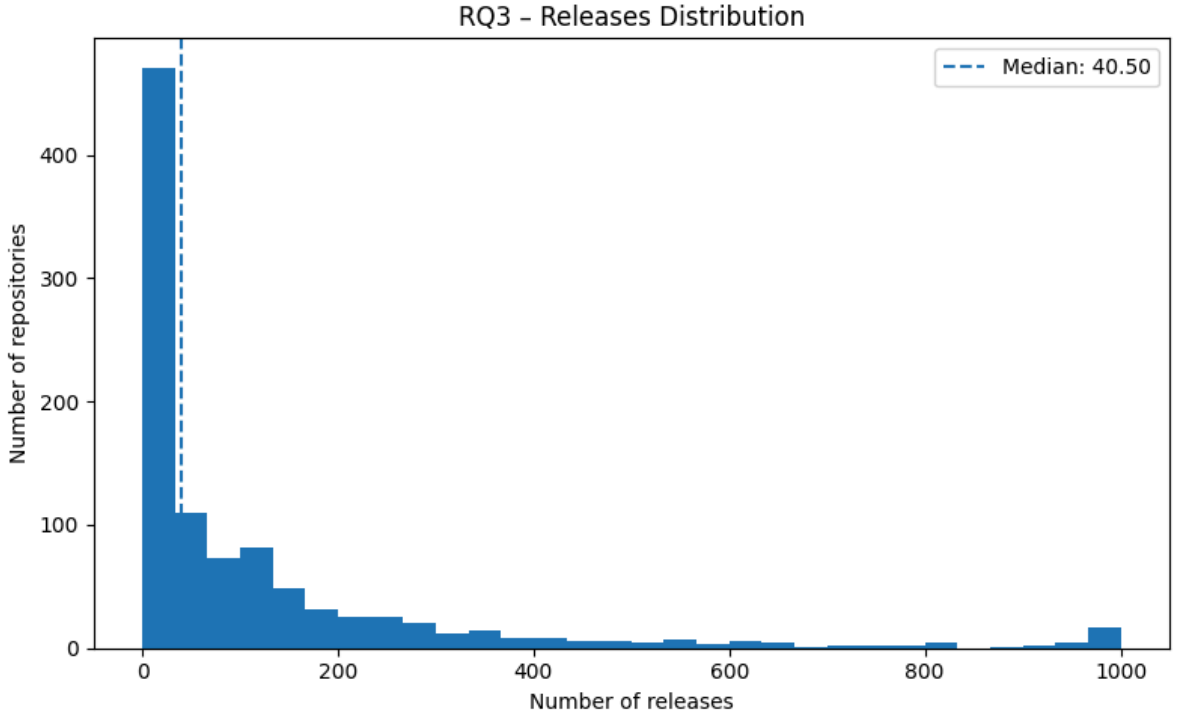

RQ4: Sistemas populares são atualizados com frequência?

A métrica utilizada foi o tempo desde a última atualização do repositório, medido em dias. A mediana encontrada foi de 1 dia.

Esse resultado indica que a maioria dos repositórios populares foi atualizada recentemente, demonstrando que esses projetos permanecem ativos e em constante manutenção. Isso sugere que projetos populares tendem a ter

desenvolvimento contínuo e comunidades engajadas.

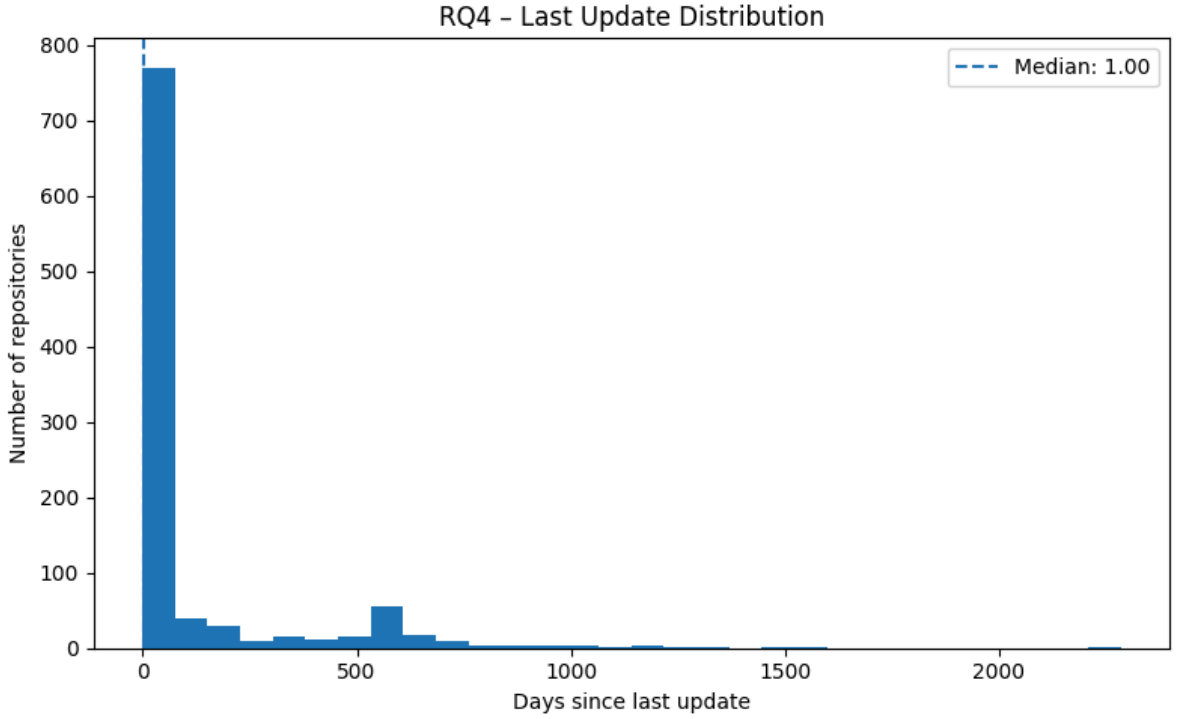

RQ5: Sistemas populares são escritos nas linguagens mais populares?

Para essa questão foi realizada uma contagem de frequência das linguagens primárias dos repositórios analisados.

As linguagens mais frequentes foram:

- Python (200 repositórios)
- TypeScript (160)
- JavaScript (115)
- Go (77)
- Rust (54)
- Java (47)
- C++ (46)

Com base na pesquisa Octoverse 2025, sistemas populares no GitHub são sim desenvolvidos majoritariamente utilizando as linguagens mais populares de 2025.

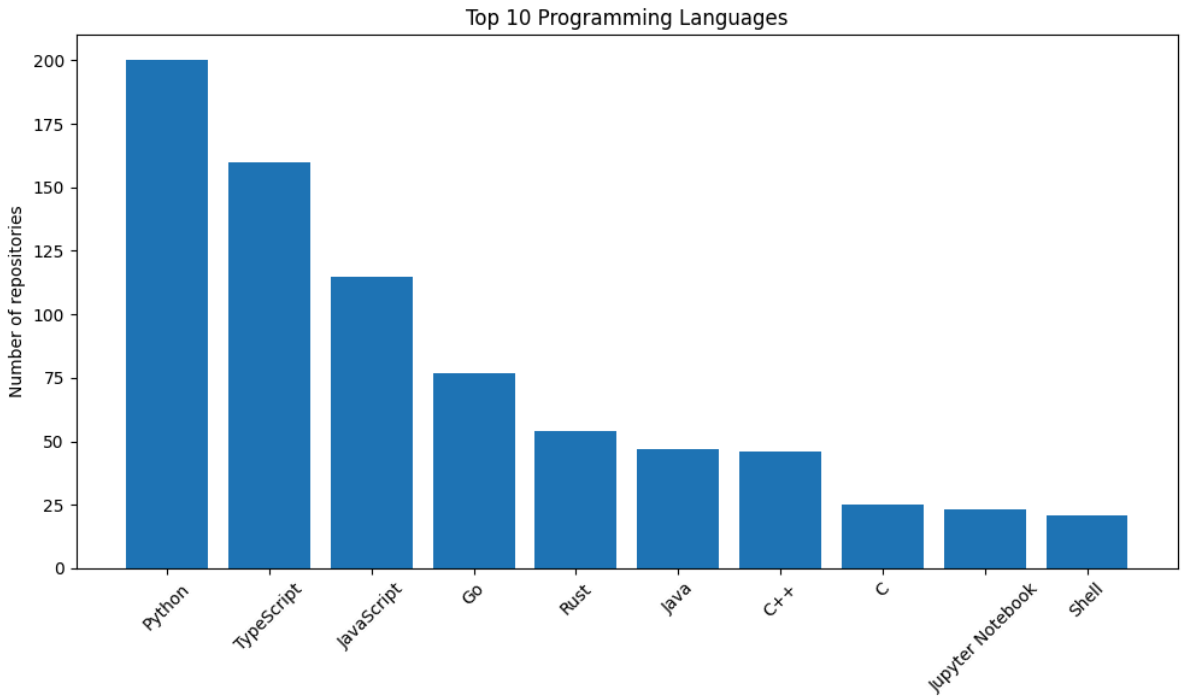

RQ6: Sistemas populares possuem um alto percentual de issues fechadas?

A métrica utilizada foi a razão entre o número de issues fechadas e o número total de issues. A mediana obtida foi de 0,867, ou aproximadamente 86,7%.

Esse valor indica que, em geral, a maior parte das issues abertas nesses projetos acaba sendo resolvida ou fechada ao longo do tempo. Isso sugere que repositórios populares costumam ter boa manutenção e acompanhamento das demandas da

comunidade, resolvendo a maioria dos problemas reportados.

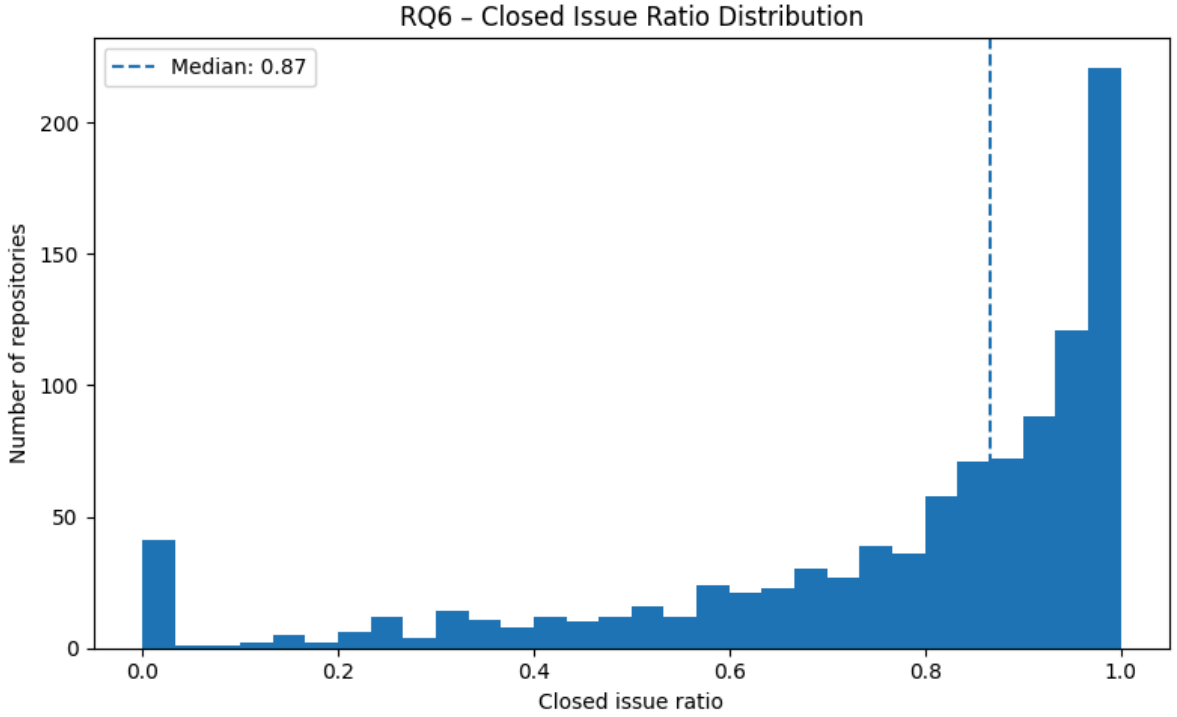

IV. Conclusão

A partir da análise dos 1.000 repositórios mais populares do GitHub, foi possível observar algumas características comuns entre esses projetos. De modo geral, os resultados indicam que muitos desses sistemas são relativamente antigos, o que sugere que a popularidade costuma estar associada a projetos que já existem há vários anos e tiveram tempo para crescer e atrair usuários.

Também foi possível observar que esses repositórios recebem uma quantidade significativa de contribuições externas, refletida no número de pull requests aceitas. Além disso, os dados mostram que os projetos continuam ativos, com atualizações muito recentes na maioria dos casos, o que indica manutenção constante e participação ativa da comunidade.

Em relação às releases, os resultados mostraram que os projetos populares possuem diversas versões publicadas ao longo do tempo. Já na análise das linguagens de programação, foi possível observar que muitas das linguagens mais utilizadas nesses repositórios também estão entre as mais populares atualmente, como Python, TypeScript e JavaScript.

Por fim, a alta proporção de issues fechadas sugere que esses projetos costumam ter um bom acompanhamento das demandas e problemas reportados pela comunidade.

De forma geral, os resultados obtidos confirmam grande parte das hipóteses iniciais e mostram que projetos populares no GitHub tendem a ser maduros, ativos e com forte participação da comunidade.